




Podstawy statystyki

Plan prezentacji



Statystyka opisowa

Jak patrzeć na dane — narzędzia do charakteryzacji i wizualizacji zbiorów danych.




Rachunek prawdopodobieństwa

Fundament niepewności — formalizacja zdarzeń losowych, zmienne losowe i ich rozkłady.



Wnioskowanie statystyczne

Jak oceniać rzeczywistość — przejście od próby do wniosków o całej populacji.



Czym jest statystyka?

Definicja i cel

Statystyka to nauka o zbieraniu, analizie i interpretacji danych w celu podejmowania trafnych decyzji w warunkach niepewności. To precyzyjny język opisu rzeczywistości.

Trzy filary statystyki

- **Opis danych:** ilościowa charakterystyka zbiorów obserwacji
- **Wnioskowanie:** ocena wiarygodności informacji i hipotez
- **Planowanie:** projektowanie eksperymentów i badań naukowych

Statystyka Opisowa

Dane mówią — statystyka tłumaczy

Statystyka opisowa to zestaw metod pozwalających zebrać dane surowe i przekształcić je w zwarte, czytelne informacje. Jej celem jest scharakteryzowanie zbioru danych bez generalizowania na szerszą populację.

Gromadzenie

Zbieranie obserwacji z eksperymentów, ankiet lub baz danych

Porządkowanie

Klasyfikacja i sortowanie danych w tabele i struktury

Prezentacja

Wizualizacja za pomocą wykresów i miar liczbowych

Interpretacja

Wyciąganie wniosków o strukturze i właściwościach danych


Prezentacja danych

Narzędzia wizualizacji

Właściwy wybór formy prezentacji danych decyduje o tym, czy odbiorca zrozumie przekaz. Każdy typ wykresu służy innemu celowi analitycznemu.

- **Histogram:** rozkład częstości zmiennej ciągłej
- **Wykres słupkowy:** porównanie kategorii
- **Wykres kołowy:** udział w całości (max. 5–6 kategorii)
- **Piktogramy:** wizualna komunikacja statystyk dla szerokiej publiczności

 Zasada: dobierz wykres do pytania badawczego, nie odwrotnie.



Przykładowy histogram — rozkład częstości obserwacji w klasach.

Miary położenia (tendencji centralnej)

Miary tendencji centralnej odpowiadają na pytanie: *wokół jakiej wartości skupiają się dane?* Każda z nich niesie nieco inne informacje i jest wrażliwa na różne właściwości zbioru.

Średnia arytmetyczna $\bar{x}$

Suma wszystkich wartości podzielona przez ich liczbę. Może być prosta, ważona lub obliczona dla danych pogrupowanych. Wrażliwa na wartości odstające.

Mediana Me

Wartość środkowa po posortowaniu zbioru. Odporna na obserwacje skrajne — preferowana przy rozkładach asymetrycznych, np. dochodów lub cen nieruchomości.

Dominanta Mo

Wartość lub klasa wartości występująca najczęściej w zbiorze. Szczególnie użyteczna dla danych jakościowych i nominalnych.

Miary zróżnicowania

Miary klasyczne

Opisują rozproszenie względem średniej arytmetycznej.

- **Wariancja (s^2):** średni kwadrat odchyłeń od średniej
- **Odchylenie standardowe (s):** pierwiastek wariancji — w tych samych jednostkach co dane
- **Współczynnik zmienności (CV):** odchylenie standardowe / średnia $\times 100\%$ — umożliwia porównanie grup o różnych skalach

Miary pozycyjne

Opisują rozproszenie na podstawie kwantyli i nie zależą od wartości ekstremalnych.

- **Rozstęp (R):** różnica między wartością maksymalną a minimalną
- **Odchylenie ćwiartkowe (Q):** połowa rozstępu międzykwartylowego IQR
- **Wykres pudełkowy (boxplot):** graficzne podsumowanie 5-liczbowe

❏ Im większa miara zróżnicowania, tym bardziej heterogeniczny zbiór danych — wyższe ryzyko błędu przy uśrednianiu.

Asymetria i kurtoza

Asymetria rozkładu

Opisuje, czy i w którą stronę rozkład jest „skrzywiony” względem jego centrum.

- **Prawostronna (dodatnia):** długi ogon w prawo — typowa dla dochodów i cen
- **Lewostronna (ujemna):** długi ogon w lewo — np. wyniki testów z łatwymi zadaniami
- **Symetryczna:** rozkład normalny, asymetria ≈ 0

Kurtoza

Mierzy „spiczastość” rozkładu — koncentrację obserwacji wokół środka lub w ogonach.

- **Leptokurtyczny:** bardziej spiczasty niż normalny (kurtoza > 3)
- **Platykurtyczny:** bardziej płaski niż normalny (kurtoza < 3)
- **Mesokurtyczny:** rozkład normalny (kurtoza $= 3$)

Excel: funkcje `SKOŚNOŚĆ()` i `KURTOZA()` umożliwiają szybką diagnostykę.



Korelacja i regresja

Współczynnik Pearsona r

Mierzy liniową zależność między dwiema zmiennymi ciągłymi. Przyjmuje wartości od -1 do $+1$. Wymaga spełnienia założeń normalności.

Współczynnik Spearmana ρ

Nieparametryczna miara monotonicznej zależności. Stosowana dla danych porządkowych lub gdy założenia normalności są naruszone.

Regresja liniowa

Modeluje zależność zmiennej objaśnianej Y od zmiennej objaśniającej X . Ocenia parametry metodą najmniejszych kwadratów (OLS).



Korelacja nie oznacza przyczynowości — zawsze weryfikuj sens merytoryczny związku!

Rachunek Prawdopodobieństwa

Matematyka niepewności

Rachunek prawdopodobieństwa dostarcza formalnego języka opisu zdarzeń losowych i jest teoretycznym fundamentem całego wnioskowania statystycznego.



Zdarzenia losowe

Algebra zbiorów, zdarzenia elementarne, przestrzeń próby, aksjomaty Kołmogorowa



Prawdopodobieństwo warunkowe

$P(A|B)$ — prawdopodobieństwo zdarzenia A pod warunkiem zajścia B. Podstawa twierdzenia Bayesa



Niezależność zdarzeń

Zdarzenia A i B są niezależne, gdy $P(A \cap B) = P(A) \cdot P(B)$. Kluczowe założenie wielu modeli

Zmienna losowa

Zmienna skokowa (dyskretna)

Przyjmuje skończoną lub przeliczalną liczbę wartości. Opisywana przez **funkcję prawdopodobieństwa** $P(X = x_i)$. Przykłady: liczba sukcesów w próbie, liczba klientów dziennie.

Zmienna ciągła

Przyjmuje wartości z przedziału liczb rzeczywistych. Opisywana przez **funkcję gęstości prawdopodobieństwa** $f(x)$, gdzie $P(a \leq X \leq b) = \text{całka z } f(x)$.

Dystrybuanta $F(x)$

Dla obu typów zmiennych: $F(x) = P(X \leq x)$. Niemalejąca, prawostronnie ciągła funkcja z $F(-\infty) = 0$ i $F(+\infty) = 1$. Unifikuje opis zmiennych losowych.

Parametry rozkładów

Każdy rozkład prawdopodobieństwa można scharakteryzować za pomocą kilku kluczowych liczb, które opisują jego kształt, położenie i rozproszenie.

$E(X)$

Wartość oczekiwana

Przewidywany wynik średni — ważona suma (lub całka) możliwych wartości z wagami równymi prawdopodobieństwom.

$Var(X)$

Wariancja

Miara rozproszenia: $E[(X - \mu)^2]$. Wyraża średnią wielkość kwadratowego odchylenia od wartości oczekiwanej.

σ

Odchylenie std.

Pierwiastek wariancji — interpretowalne w oryginalnych jednostkach. Reguła 68–95–99,7% dla rozkładu normalnego.

Kluczowe rozkłady teoretyczne



Rozkład dwumianowy $B(n, p)$

Modeluje liczbę sukcesów w n niezależnych próbach Bernoulliego, każda z prawdopodobieństwem sukcesu p .

Zastosowania: kontrola jakości, testy A/B.



Rozkład Poissona $Po(\lambda)$

Opisuje liczbę rzadkich zdarzeń w jednostce czasu lub przestrzeni przy stałym natężeniu λ . Przykłady: awarie sieci, zgłoszenia do call center, mutacje DNA.



Rozkład normalny $N(\mu, \sigma^2)$

Fundamentalny rozkład statystyki — symetryczny, dzwonowaty, opisany przez μ i σ . Centralne Twierdzenie Graniczne gwarantuje jego powszechność.

Rozkłady specjalistyczne

Rozkład chi-kwadrat $\chi^2(k)$

Suma kwadratów k niezależnych zmiennych standardowych normalnych. Stosowany w testach zgodności, niezależności oraz modelowaniu częstości. Kształt silnie asymetryczny, zbliżający się do normalnego wraz ze wzrostem stopni swobody.

Rozkład t-Studenta $t(k)$

Zbliżony do normalnego, lecz z cięższymi ogonami — kluczowy przy wnioskowaniu o średniej, gdy wariancja populacji jest nieznana. Stosowany dla małych prób ($n < 30$).

Rozkład Fishera-Snedecora $F(k_1, k_2)$

Iloraz dwóch niezależnych zmiennych chi-kwadrat podzielonych przez ich stopnie swobody. Podstawa analizy wariancji (ANOVA) i testowania istotności modeli regresji.

Zastosowania praktyczne

- **Inżynieria:** kontrola jakości, analiza niezawodności systemów
- **Biologia/medycyna:** analiza przeżycia, badania kliniczne
- **Ekonomia:** modelowanie stóp zwrotu, analizy ryzyka

Wnioskowanie Statystyczne

Wnioskowanie statystyczne to most między próbą a populacją. Na podstawie ograniczonej liczby obserwacji formułujemy wnioski o całym zjawisku — zawsze z mierzalną niepewnością.

1

Populacja

Pełny zbiór jednostek zainteresowania — często nieobserwowalny

2

Próba losowa

Podzbiór populacji wybrany metodą zapewniającą reprezentatywność

3

Estymacja / Test

Narzędzia statystyczne do generalizacji wyników z próby na populację



Estymacja punktowa i przedziałowa

Estymacja punktowa

Polega na podaniu jednej konkretnej wartości jako szacunku parametru populacji (np. $\hat{\mu} = \bar{x} = 4,72$). Estymator powinien być **nieobciążony**, **zgodny** i **efektywny**. Błąd standardowy mierzy przeciętną odległość estymatora od prawdziwej wartości parametru.

Estymacja przedziałowa

Zamiast jednej liczby podajemy **przedział ufności** $[d, g]$, który z zadaniem prawdopodobieństwem $(1 - \alpha)$ zawiera nieznaną wartość parametru.

- Współczynnik ufności $1 - \alpha$ (np. 0,95) określa naszą pewność co do procedury
- Szerokość przedziału zależy od: rozmiaru próby, wariancji i poziomu ufności
- Większa próba $\rightarrow$ węższy przedział $\rightarrow$ precyzyjniejsza ocena

Testowanie hipotez

Testowanie hipotez to formalna procedura oceny twierdzeń o parametrach populacji na podstawie danych z próby.

1

Hipotezy H_0 i H_1

Hipoteza zerowa H_0 zakłada brak efektu (status quo). Hipoteza alternatywna H_1 wyraża to, co chcemy udowodnić. Test dostarcza dowodów przeciw H_0 .

2

Błędy decyzyjne

Błąd I rodzaju (α): odrzucenie prawdziwej H_0 — „fałszywy alarm”. **Błąd II rodzaju (β):** nieodrzućenie fałszywej H_0 — „przeoczenie efektu”. Moc testu = $1 - \beta$.

3

Poziom istotności i p-wartość

Poziom istotności α (najczęściej 0,05) to akceptowany odsetek błędów I rodzaju. P-wartość to prawdopodobieństwo uzyskania wyniku tak ekstremalnego jak obserwowany, jeśli H_0 jest prawdziwa.

Procedura testowa



Sformułowanie hipotez

H_0 i H_1 jasno określone



Wybór statystyki

Dobór testu i założeń




Obliczenie wyników

Statystyka i p-wartość



Podjęcie decyzji

Odrzucić lub nie odrzucić H_0



Poprawna procedura testowania wymaga nie tylko obliczenia statystyki, ale przede wszystkim weryfikacji założeń modelu (normalność, jednorodność wariancji, niezależność obserwacji). Naruszenie założeń może prowadzić do fałszywych wniosków — wówczas warto sięgnąć po testy nieparametryczne.

Nowoczesne Wnioskowanie: Od Testów do Przewidywania

Uogólnione Modele Liniowe (GLM)

Elastyczne rozszerzenie regresji liniowej pozwalające modelować zmienne binarne (regresja logistyczna), liczby (regresja Poissonowska) i proporcje. Fundament współczesnych algorytmów klasyfikacji.

Predykcja i modelowanie

Klasykzna weryfikacja hipotez ustępuje miejsca modelowaniu predykcyjnemu: zamiast pytać „czy efekt istnieje?”, pytamy „jak duży jest i jak precyzyjnie możemy go przewidzieć?”.

Wyzwania big data

Przy ogromnych zbiorach danych niemal każdy efekt staje się statystycznie istotny. Kluczowe stają się: nadwyżka rozproszenia, analiza głównych składowych (PCA) i metody regularyzacji (Lasso, Ridge).





Statystyka: Kompas w Oceanie Informacji

Każdy model jest błędny — ale niektóre modele są użyteczne. — *George Box*

Język opisu

Statystyka to precyzyjny system pojęć pozwalający ograniczać niepewność i komunikować wiedzę w sposób mierzalny.

Kompletna ścieżka

Od analizy opisowej, przez rachunek prawdopodobieństwa, aż po zaawansowane wnioskowanie przyczynowe i predykcyjne.

Umiejętność XXI w.

Krytyczna interpretacja wyników i świadomość ograniczeń modeli zmienia surowe dane w mądre, odpowiedzialne decyzje.